AgroParisTech

PROJET FIL ROUGE

RAPPORT FINAL

AFZ - Prédiction de valeurs nutritionnelles

Élèves :

François FARAMUS
Pierre-Jean GOUZE
Baptiste GRANIER
Valentine MICHELET
Alan TURBOT

Encadré par :

Antoine CORNUÉJOLS
Vincent GUIGUE
Valérie HEUZE
Christine MARTIN
Gilles TRAN

13 mars 2026

Table des matières

1 Introduction **2**

2 Présentation des données principales **2**
2.1 Données AFZ . . . 2
2.2 Feedtables . . . 3

3 Analyse *In Distribution* **4**
3.1 Méthodologie . . . 5
3.2 Modèles de référence . . . 6
3.2.1 Définition des modèles de référence . . . 6
3.2.2 Résultats . . . 6
3.3 Robustesse du modèle face au bruit . . . 7
3.3.1 Objectif et méthode . . . 7
3.3.2 Résultats . . . 8
3.4 Robustesse du modèle face aux valeurs manquantes . . . 8
3.4.1 Objectif et méthode . . . 8
3.4.2 Résultats . . . 9
3.5 Intervalles de confiance des prédictions . . . 10
3.6 Conclusion de partie . . . 11

4 Analyse en OOD **11**
4.1 Prédire en OOD avec XGBoost . . . 11
4.2 Utilisation du deep learning . . . 13
4.2.1 Méthodologie . . . 13
4.2.2 Définition des embeddings . . . 14
4.2.3 Réduction du nombre de dimensions des embeddings par auto-encodage . . . 15
4.2.4 Premier modèle : Perceptron multi-couche . . . 15
4.2.5 Deuxième modèle qui permet de mieux gérer l'OOD et l'imputation de valeurs : le transformer . . . 16
4.3 Résultats de la partie deep learning . . . 17
4.3.1 Effet de l'OOD sur l'auto-encodeur . . . 17
4.3.2 Mesure des valeurs OOD : MLPRegressor vs Transformer . . . 18
4.3.3 Imputation de valeurs par transformer . . . 19

5 Discussion **21**
5.1 Synthèse des résultats . . . 21
5.2 Recherche des causes d'erreur en OOD : remise en question de la représentation sémantique . . . 22
5.3 Vers un usage utilisateur . . . 23
5.4 Piste d'ouverture . . . 23

6 Conclusion **23**

Références **25**

1 Introduction

L'évaluation des valeurs nutritionnelles des aliments destinés à l'alimentation animale constitue un enjeu central en zootechnie, tant pour l'optimisation des performances zootechniques que pour la maîtrise des coûts et des impacts environnementaux. Ces valeurs reposent sur des modèles complexes intégrant de nombreuses composantes chimiques et physiologiques, et varient selon les espèces animales considérées. En pratique, leur estimation repose encore largement sur des bases de données tabulaires et des chaînes d'équations successives non linéaires, dont la manipulation demeure difficile et peu flexible.

L'Association Française de Zootechnie (AFZ) dispose ainsi d'une base de références nutritionnelles pour des produits alimentaires destinés aux animaux, notamment aux espèces monogastriques. Elle souhaite utiliser cette base de données comme référence afin d'automatiser les prédictions à partir de modèles d'apprentissage automatique.

Le projet fil rouge co-construit avec l'AFZ s'inscrit dans cette démarche, en proposant de développer des modèles de prédiction capables d'estimer les valeurs nutritionnelles à partir d'un ensemble restreint de variables décrivant la composition chimique des aliments. Nous étudions la robustesse de ces modèles selon trois axes complémentaires. Premièrement, nous analysons leurs performances dans un cadre *In-Distribution* (ID), où les données de test suivent la même distribution que les données d'entraînement. Deuxièmement, nous examinons l'impact de la présence de variables d'entrée manquantes et comparons différentes stratégies d'imputation afin de préserver la qualité des prédictions. Enfin, nous évaluons leur comportement en situation *Out-of-Distribution* (OOD), caractérisé par un décalage distributionnel pouvant survenir pour des matières premières nouvelles ou peu représentées. L'objectif global est d'identifier des approches robustes et opérationnelles permettant d'améliorer la généralisation des modèles et de faciliter l'automatisation fiable de l'estimation des valeurs nutritionnelles dans des contextes réels d'utilisation.

2 Présentation des données principales

2.1 Données AFZ

Les données utilisées dans ce projet ont été fournies par l'AFZ. Elles se présentent sous la forme d'une base de données décrivant des aliments destinés à l'alimentation animale.

La base de données de l'AFZ se présente ainsi et décrit, pour chaque échantillon :

- Son profil chimique : ("MS % brut", "PB % brut", "CB % brut", "MGR % brut", "MM % brut", "NDF % brut", "ADF % brut", "Lignine % brut", "Amidon % brut", "Sucres % brut")
- Les variables nutritionnelles associées : ("EB (kcal) kcal/kg brut", "ED porc croissance (kcal) kcal/kg brut", "EM porc croissance (kcal) kcal/kg brut", "EN porc croissance (kcal) kcal/kg brut", "EMAn coq (kcal) kcal/kg brut", "EMAn poulet (kcal) kcal/kg brut", "UFL 2018 par kg brut", "UFV 2018 par kg brut", "PDIA 2018 g/kg brut", "PDI 2018 g/kg brut", "BalProRu 2018 g/kg brut")

Cette base de données comprend 73 produits (référés par un "Nom") différents et tota-

Nom	MS% brut	PB % brut	CB % brut	MGR % brut	MM % brut	NDF % brut	ADF % brut	Lignine % brut	Amidon % brut	Sucres % brut
Avoine	87	9,5	12,6	3,2	3,8	33,4	15,4	2,4	46,2	1,4
Avoine	87	11,9	11,8	2,6	2,5	31,7	14,5	2,3	44,4	1,7

EB (kcal) kcal/kg brut	ED porc croissance (kcal) kcal/kg	EM porc croissance (kcal) kcal/kg	EN porc croissance (kcal) kcal/kg	EMAn coq (kcal) kcal/kg brut	EMAn poulet (kcal) kcal/kg brut	UFL 2018 par kg brut	UFV 2018 par kg brut	PDIA 2018 g/kg brut	PDI 2018 g/kg brut	BalPro Ru 2018 g/kg brut
3920	2460	2380	1850	2610	2480	0,81	0,76	17	62	-10
3970	2580	2480	1880	2590	2460	0,88	0,85	22	69	5

FIGURE 1 – Extrait de la base de données de l'AFZ

lise 6422 échantillons. Les données physico-chimiques et les valeurs nutritionnelles sont issues d'analyses standardisées effectuées en laboratoire ou en station expérimentale et permettent de caractériser chaque échantillon. Il est important de noter la qualité de ces informations recueillies par l'AFZ. Elles ont facilité la création des modèles prédictifs mis en place dans la suite de ce travail. Cependant, la qualité et la complétude de ces données est rarement observée sur le terrain. Ainsi, les modèles mis en place dans cette étude devront être capables de traiter des données incomplètes ou de qualité moindre.

D'après l'ACP, en figure 2, obtenue à partir des variables physico-chimiques, nous observons des profils distincts entre différentes espèces (caractérisées par le descripteur "Nom"). Cette variabilité sera exploitée dans nos futurs modèles.

2.2 Feedtables

Au cours de certaines expériences, une table complémentaire à celle fournie par l'AFZ sera utilisée. Ces données sont issues d'une base de données intitulée FeedTables [1].

Cette table est similaire dans la structure à celle de l'AFZ et nous permet d'avoir accès, pour une vaste diversité de produits, aux valeurs moyennes des variables physico-chimiques et nutritives (il existe une ligne par aliment).

Elle comprend plus d'aliments différents que la base de données AFZ. Il est important de noter que l'ensemble des aliments présents dans les données AFZ sont inclus dans cette base de données plus large.

Lorsque nous utilisons Feedtables, un prétraitement de cette base de données est effectué au préalable. Il permet de supprimer les aliments du type minéraux et acides aminés non utiles pour notre travail (ces derniers ne rentrent pas dans le cadre d'étude établi).

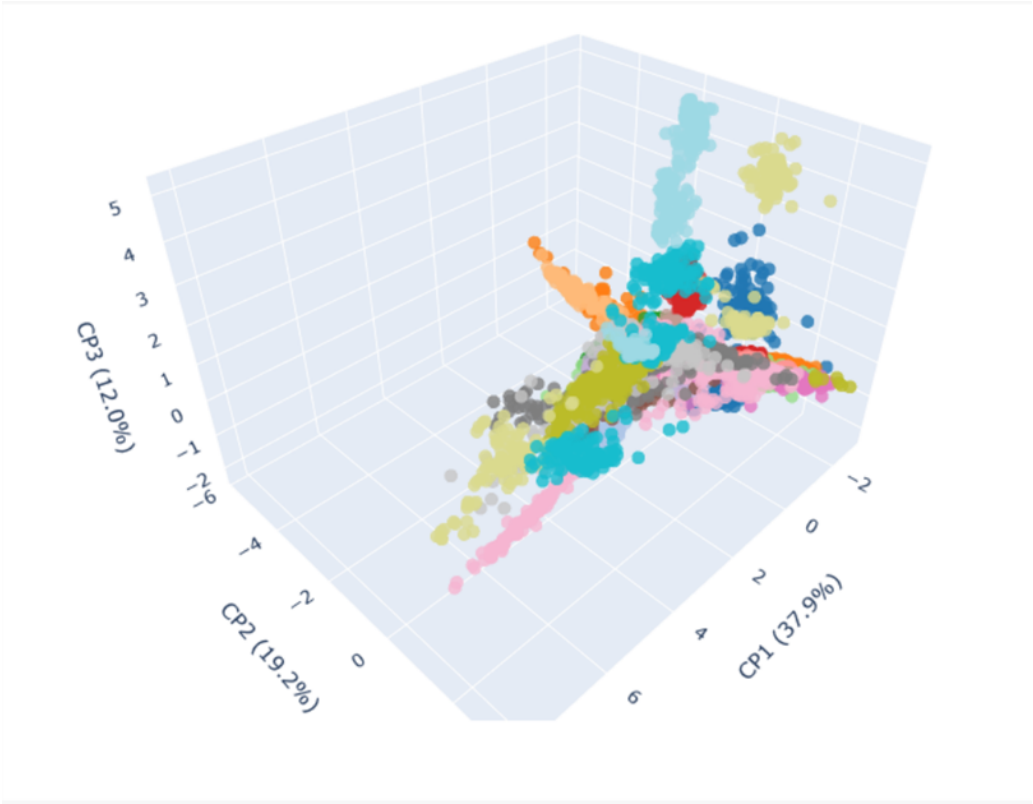

FIGURE 2 – Variabilité des noms au sein de la base de données

De plus, en complément du nom de l'aliment, une définition textuelle y est associée. Celle-ci sera également exploitée dans certaines de nos expériences.

3 Analyse *In Distribution*

L'objectif de cette première partie est d'établir un modèle permettant de prédire les variables nutritionnelles d'un échantillon *In Distribution* (ID) à partir de ses caractéristiques.

Nous définissons la situation *In Distribution* à l'aide du schéma ci-dessous :

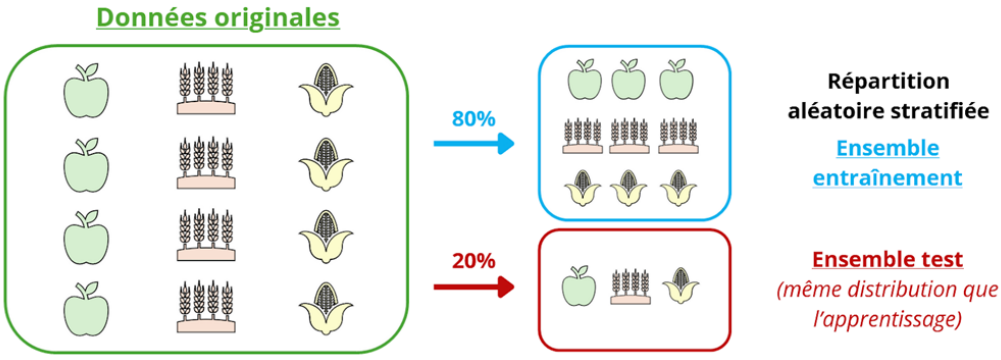

FIGURE 3 – Schéma de la constitution des ensembles de test et d'entraînement dans une configuration *In Distribution*

La figure 3 présente les modalités des tests *In Distribution* réalisés. La répartition entre l'ensemble de test et d'entraînement se fait selon une répartition aléatoire stratifiée de sorte à ce que tous les noms des échantillons vus en test aient été vus en entraînement.

3.1 Méthodologie

Pour l'ensemble de cette partie, la méthodologie suivante a été appliquée :

- La séparation aléatoire stratifiée des données en deux ensembles (train/test, 80/20) a été réalisée afin d'assurer une répartition proportionnelle des produits (variable "Nom") dans chaque ensemble. Cette méthode permet de limiter les biais liés à une distribution hétérogène des catégories et garantit la représentativité des données lors de l'évaluation du modèle.
- Le choix du modèle XGBoost s'appuie sur plusieurs critères : sa simplicité de mise en œuvre, son efficacité reconnue sur les données tabulaires [2,3], ainsi que sa capacité à capturer des interactions non linéaires entre variables. Ces caractéristiques en font un outil adapté à notre problématique, où les relations entre variables physico-chimiques et nutritionnelles peuvent être complexes.
- Pour le traitement des variables catégorielles, nous avons opté pour l'encodage *One Hot*, principalement en raison de sa simplicité d'implémentation. Nous sommes conscients que cette méthode ne permet pas de représenter la proximité entre catégories (toutes les catégories sont orthogonales) et que le nombre de catégories reste fixe lors de l'inférence. Toutefois, dans le cadre de cette première approche, cette solution s'est révélée adaptée et efficace pour cette partie.

Nous rappelons ici les variables d'entrée potentielles et les variables cibles :

Nom de la variable d'entrée	**Nom de la variable d'entrée**
Nom	MS % Brut
PB % Brut	CB % Brut
MGR % Brut	MM % Brut
NDF % Brut	Lignine % Brut
Amidon % Brut	Sucre % Brut

Table 1 – Variables d'entrée du modèle

Nom de la variable cibles	**Nom de la variable cibles**
EB (kcal) kcal/kg brut	ED porc croissance (kcal) kcal/kg brut
EM porc croissance (kcal) kcal/kg brut	EN porc croissance (kcal) kcal/kg brut
EMAn coq (kcal) kcal/kg brut	EMAn poulet (kcal) kcal/kg brut
UFL 2018 par kg brut	UFV 2018 par kg brut
PDIA 2018 g_kg brut	PDI 2018 g_kg brut
BalProRu 2018 g_kg brut	/

Table 2 – Variables cibles du modèle

3.2 Modèles de référence

3.2.1 Définition des modèles de référence

Les chercheurs de l'AFZ soulignent l'importance des variables textuelles concernant la qualité de la prédiction. En effet, selon eux, les variables physico-chimiques seules ne suffiraient pas à prédire précisément les valeurs nutritionnelles d'un aliment : pour deux aliments de nature différentes mais qui présentent des profils physico-chimiques similaires, les variables nutritives ne seront pas forcément égales. Nous avons donc inclus la variable "Nom du produit" et souhaitons discuter de sa pertinence.

Nous définissons donc dans un premier temps trois modèles de références :

- **All_features+Nom** : Un modèle qui possède l'ensemble des descripteurs physico-chimiques ainsi que du nom de l'aliment pour prédire les valeurs cibles. Ce scénario représente le cas idéal qui sera donc une référence de performance maximum atteignable.
- **All_features** : Un modèle qui possède uniquement les variables physico-chimiques pour prédire les valeurs nutritionnelles et vérifier l'hypothèse des chercheurs de l'AFZ.
- **Nom** : Un modèle naïf qui ne possède que le nom en entrée. Cela revient à fournir une valeur moyenne de l'aliment.

L'objectif est de comparer les autres modèles du reste de cette étude aux performances de ces trois modèles de référence.

3.2.2 Résultats

Modèle	All_features + Nom	All_features	Nom
XGBoost	0.9915 ± 0.00082	0.9904 ± 0.00097	0.9333 ± 0.0196

TABLE 3 – R^2 moyen des modèles de références. Les écarts types sont obtenus après 5 répétitions des expériences sur des ensembles d'apprentissage et de tests différents (validation croisée à 5 plis)

Au vu des résultats montrés dans la table 3, nous observons que les performances de prédiction sont relativement fiables pour les 3 modèles. Le modèle Nom, naïf, qui propose une valeur moyenne, permet de prédire avec une performance au R^2 de 0,93 et montre à quel point la variable "Nom" est informative. Ce résultat signifie que nous avons une faible diversité intra espèce d'aliment et que ces aliments sont rapprochés autours de la valeur moyenne de leur catégorie. À l'opposé, un modèle que l'on considère comme "complet" réalise des prédictions quasi parfaites, avec un R^2 proche de 1. Une idée serait donc de simplifier le modèle et d'observer dans quelle mesure nous pouvons obtenir des résultats semblables avec moins de variables d'entrées, comme cela sera le cas dans un cadre opérationnel. En effet, dans la réalité, il est peu probable d'avoir toutes les informations physico-chimiques relatives aux aliments. Les performances du modèle utilisant exclusivement les variables physico-chimiques permettent d'évaluer l'hypothèse formulée par les experts quant à l'explicabilité des valeurs nutritionnelles à partir de caractéristiques chimiques. Les résultats obtenus montrent que ces variables, prises isolément, permettent

d'atteindre un niveau de précision comparable à celui du modèle All_features+Nom. L'ajout de l'information "Nom" de l'aliment améliore très légèrement les performances prédictives ; cette variable sera donc intégrée dans la suite des expérimentations lorsque cela est possible.

3.3 Robustesse du modèle face au bruit

3.3.1 Objectif et méthode

Nous souhaitons montrer la robustesse du modèle All_features+Nom face au bruit appliqué aux variables d'entrée, qui peut résulter de biais expérimentaux. Pour ce faire, nous réalisons les étapes suivantes :

Algorithme 1 Injection de bruit gaussien et évaluation des performances

Entrée : Données numériques X, variable catégorielle Nom
Paramètre : $\theta \in [0, 1]$ avec un pas de 0,05
Normaliser et centrer l'ensemble des variables numériques à partir de l'ensemble d'apprentissage (afin d'assurer un poids relatif homogène du bruit)
for chaque valeur de θ **do**
  Définir un bruit gaussien $\varepsilon \sim \mathcal{N}(0, \theta)$
  Ajouter ε aux variables numériques
    (sur le train, le test ou les deux selon le scénario)
  Appliquer la transformation inverse pour revenir dans l'espace initial
  Ajouter la variable catégorielle *Nom* (encodage One-Hot)
  Entraîner les modèles
  Calculer et enregistrer les R^2 moyens des variables cibles
end for

Nous appliquons ce protocole sur le modèle de référence All_features+Nom avec l'ensemble des variables d'entrées avec le nom. Ce bruit est appliqué dans 3 situations différentes :

- La première est l'application de ce bruit sur les variables physico-chimiques des échantillons d'entraînement. Ce processus va faire office de régularisation des variables d'entrée et a pour but de rendre le modèle plus robuste.
- La deuxième situation est l'application du bruit sur les échantillons relatifs à l'ensemble de test. Cette approche permet d'évaluer la sensibilité du modèle aux erreurs de mesure affectant les variables d'entrée lors de son utilisation en conditions réelles, c'est-à-dire face à une incertitude sur les données observées. C'est la situation la plus réaliste pour nos expériences, car sur le terrain, les données fournies pour réaliser des prédictions seront nécessairement de qualité plus variable que celles utilisées pour l'entraînement.
- Le troisième scénario permet de mettre en évidence le comportement global du modèle dans un contexte où l'ensemble des données est affecté par une incertitude de mesure, simulant ainsi un environnement entièrement bruité. Ce cas reste toutefois peu vraisemblable au regard de la qualité des données dont nous disposons pour l'entraînement.

3.3.2 Résultats

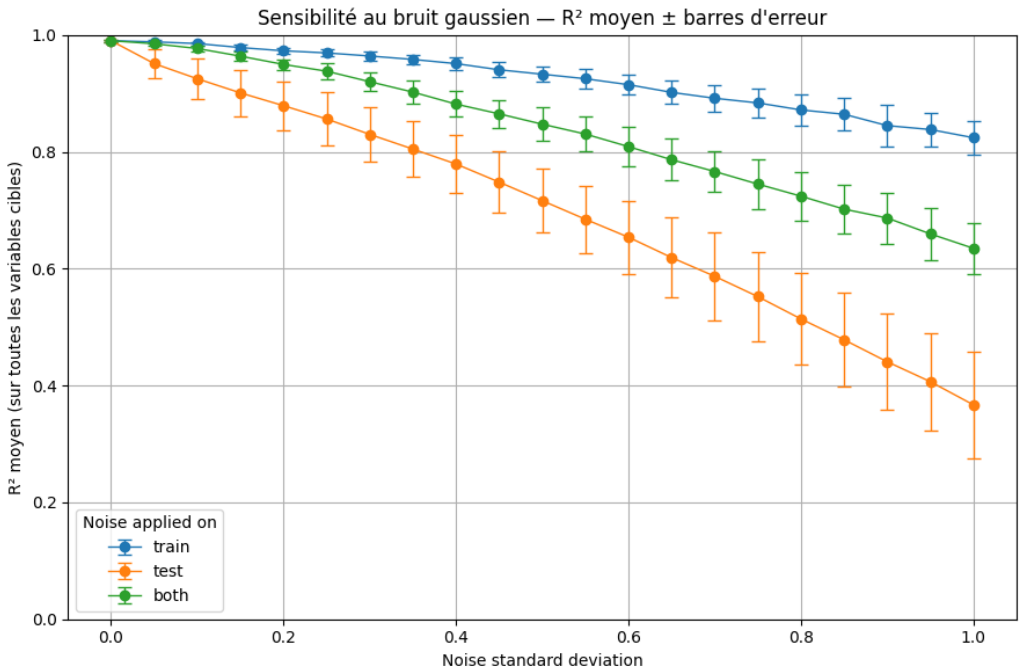

FIGURE 4 – R^2 en fonction de θ du bruit gaussien et des 3 scénarios définis ci-dessus

Ces résultats sont plutôt prévisibles : plus nous augmentons le bruit, moins la prédiction sera bonne. Nous ne notons pas d'amélioration des performances en cas d'ajout de bruit dans toutes les configurations. Sur des petites perturbations de bruits ($< 0{,}2$ soit une modification de la valeur initiale de $\pm 20\%$), le modèle reste relativement stable. Nous pouvons dire qu'il est résistant au bruit et aux différentes erreurs d'utilisation de la part de l'utilisateur. Toutefois, nous observons que lorsque le bruit est ajouté uniquement sur l'ensemble de test (scénario le plus réaliste pour nos expériences), le modèle devient plus sensible aux perturbations des variables d'entrée que dans les autres scénarios. Il montre une sensibilité accrue face à des perturbations plus importantes ou inédites. Cela reste à nuancer car un bruit supérieur à 50% (std = 0,5) représente une situation absurde où l'opérateur rentre des valeurs erronées dans le modèle.

NB : Une expérience complémentaire aurait pu consister à ajouter des valeurs bruitées en plus des valeurs correctes lors de l'entraînement afin de réaliser une augmentation de données.

3.4 Robustesse du modèle face aux valeurs manquantes

3.4.1 Objectif et méthode

La base de données fournie par l'AFZ constitue un jeu de données idéal, exhaustif et parfaitement renseigné, toutes les valeurs physico-chimiques associées à chaque produit y sont présentes. En pratique, l'opérateur ne disposera pas de l'ensemble des variables physico-chimiques d'un produit. Après avoir discuté avec les experts, nous savons que

le nom du produit est toujours connu ainsi que la matière sèche (MS) et les protéines brutes (PB). Malheureusement, les autres variables (ADF, lignines, sucres, etc.) ne sont renseignées qu'en fonction de la typologie de produit étudiée par rapport à son intérêt agronomique. Par exemple, un maïs ou un blé posséderont toujours le descripteur amidon tandis qu'un tourteau n'aura pas ce descripteur mais MGR à la place. Un quatrième modèle intitulé MS_PB+Nom est alors mis en place (selon les mêmes configurations que précédemment) afin de tester les performances prédictives d'un modèle incomplet. Ce modèle sera comparé avec le modèle All_features+Nom soumis au protocole ci-dessous :

Algorithme 2 Protocole de masquage aléatoire

1 : **Entrée :** Données physico-chimiques X
2 : **Sortie :** Performances du modèle après masquage
3 : **for** $k = 1$ **to** 8 **do**
4 : Sélectionner aléatoirement k variables physico-chimiques
5 : (hors MS et PB)
6 : Masquer ces variables pour chaque élément prédit
7 : Imputer les valeurs masquées avec les valeurs moyennes issues de la table *Feedtables*
8 : **end for**
9 : Évaluer les performances sur l'ensemble d'apprentissage

3.4.2 Résultats

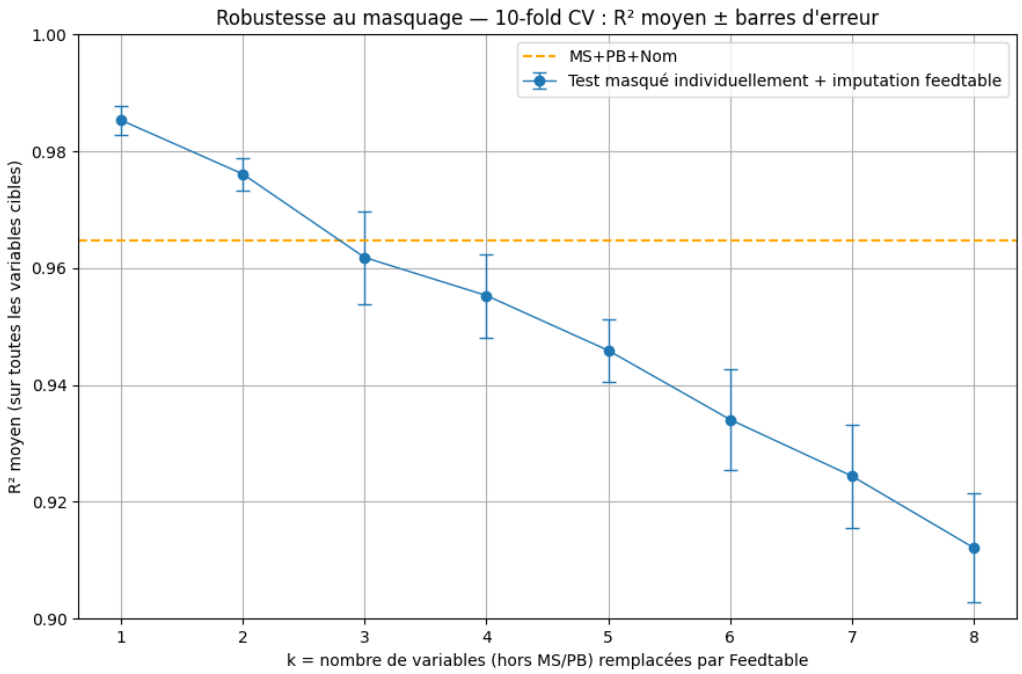

FIGURE 5 – Graphique représentant le R^2 moyen en fonction du nombre de variables imputées comparé au modèle MS_PB+Nom (en pointillés orange)

Le modèle MS_PB+Nom, incomplet, reste relativement performant avec un R^2 moyennant 0,965. Imputer les valeurs manquantes par les valeurs moyennes de Feedtables présente un réel intérêt s'il manque au maximum 3 variables. Au-delà, il vaut mieux se fier

aux prédictions du modèle incomplet. En effet, plus le nombre de valeurs imputées est important, plus nous ajoutons du bruit qui diminue le pouvoir prédictif du modèle.

NB : Les discussions avec les experts nous ont amenés à envisager des modèles adaptatifs, moins complets que All_features+Nom mais qui possèdent des combinaisons réduites des variables d'intérêt en fonction du produit que nous cherchons à prédire. Par exemple, réaliser un modèle XGBoost_céréales, qui posséderait MS_PB_Amidon_Sucre pour les céréales.

3.5 Intervalles de confiance des prédictions

Afin d'accroître la robustesse des prédictions dans une perspective d'utilisation en conditions réelles, des intervalles de confiance ont été construits autour des valeurs prédites. Deux configurations ont été considérées : (i) All_features+Nom, et (ii) MS_PB+Nom. Pour chacune de ces configurations, une série de prédictions a été générée à partir de modèles entraînés selon une procédure de bootstrap comportant 30 itérations. Les intervalles de confiance à 95 % ont ensuite été estimés à partir de la distribution empirique des prédictions obtenues. Ces intervalles correspondent à ceux intégrés dans le démonstrateur applicatif transmis à l'AFZ dans le cadre du projet. La figure 6 illustre la variabilité des prédictions au sein des catégories "Nom". L'ensemble des modèles issus de la procédure de bootstrap pour la configuration All_features+Nom présente un R^2 supérieur à 0,99.

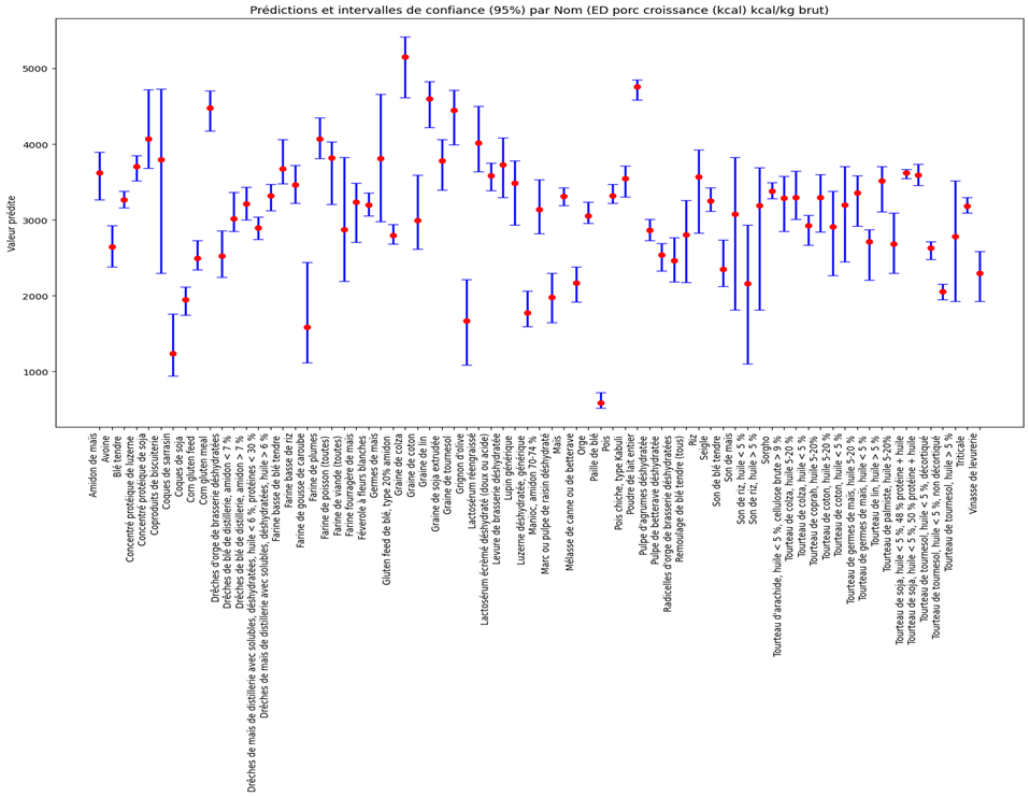

FIGURE 6 – Graphique présentant les prédictions moyennes et les intervalles de confiance issus de la méthode de bootstrap pour le modèle XGBoost entraîné avec toutes les variables physico-chimiques.

3.6 Conclusion de partie

Notre approche avec des modèles ensemblistes tels que XGBoost est très prometteuse aux premiers abords avec d'excellentes performances dans un cadre idéal. Celui-ci semble également relativement robuste face à des données ID bruitées. De plus, un modèle incomplet comprenant MS_PB+Nom permet de maintenir des performances ID correctes dans un cas plus réaliste où l'utilisateur ne disposerait pas de toutes les informations relatives au produit. Dans le cas où il manquerait au plus trois variables d'entrée, un modèle qui impute ces valeurs manquantes par des valeurs moyennes semble meilleur que le modèle incomplet MS_PB+Nom. Ainsi, les modèles mis en place via XGBoost dans cette partie constituent alors une base solide pour prédire les valeurs nutritionnelles d'aliments ID. Par la suite, nous allons nous intéresser aux aliments *Out of Distribution* et évaluer les performances de ce modèle.

4 Analyse en OOD

Compte tenu des performances de nos modèles en situations ID, il est cohérent d'évaluer les performances dans des conditions dites *Out-Of-Distribution* (OOD) et de cerner les limites des modèles établis précédemment. Dans un souci de généralisation du modèle, traiter les situations OOD permettrait aussi de faire face à des cas concrets qui seraient observés sur le terrain lorsque l'opérateur chercherait à obtenir des prédictions pour des aliments non répertoriés dans la base de données. Nous définissons la situation *Out-Of-Distribution* à l'aide du schéma ci-dessous :

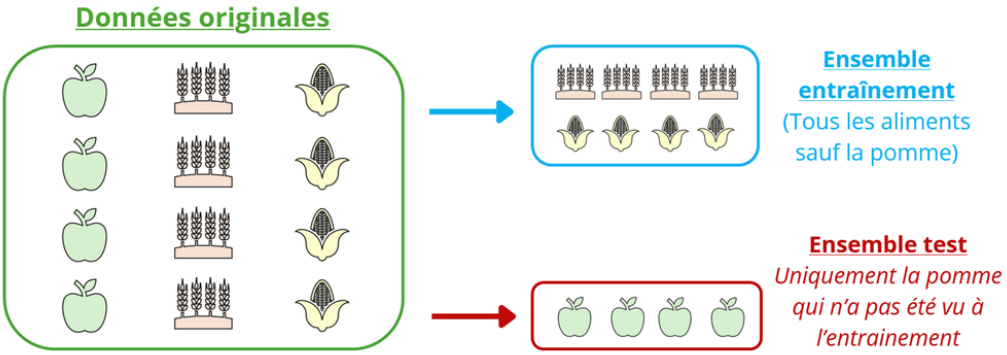

FIGURE 7 – Schéma de la constitution des ensembles de test et d'entraînement dans une configuration *Out-Of-Distribution*

D'après la figure 7, l'*Out-Of-Distribution* (OOD) désigne une situation où le modèle doit proposer une prédiction sur un échantillon dont le nom n'a jamais été observé lors des phases d'entraînement.

4.1 Prédire en OOD avec XGBoost

L'objectif est d'évaluer la robustesse et la capacité de généralisation du modèle XGBoost pour la prédiction de variables nutritionnelles, en comparant ses performances en ID et

en OOD. La méthodologie consiste à quantifier l'impact de la situation (ID vs OOD) sur la performance du modèle, en cachant certains produits lors de l'entraînement et en l'évaluant sur ceux-ci. Il est important de noter que le *one-hot encoding* n'est pas applicable dans ce contexte : la variable catégorielle "Nom" représente des produits uniques, et chaque produit caché en OOD n'aurait aucune colonne active dans le test, rendant impossible la prédiction pour un produit jamais vu par XGBoost. Le modèle All_features est donc utilisé à titre de comparatif ID, avec un split aléatoire stratifié par produit afin de pallier la problématique liée à l'impossibilité d'utiliser du *one-hot encoding*.

De plus, au vu des résultats obtenus en ID dans la partie précédente, on peut émettre l'hypothèse que les variables physico-chimiques suffisent à elles seules au modèle pour prédire les valeurs énergétiques métabolisées des animaux d'aliments inconnus de la table.

Afin de simuler le scénario OOD, le processus suivant a été mené en procédant à des validations croisées à chaque itération afin d'obtenir des statistiques sur les performances :

- 1 produit différent est caché lors de l'entraînement (non inclus dans le train),
- le modèle est évalué sur ces produits cachés,
- les scores R^2 sont collectés pour chaque produit caché, puis agrégés pour obtenir des statistiques globales.

Ce processus est nommé Leave-One-Product-Out (LOPO) dans nos expériences.

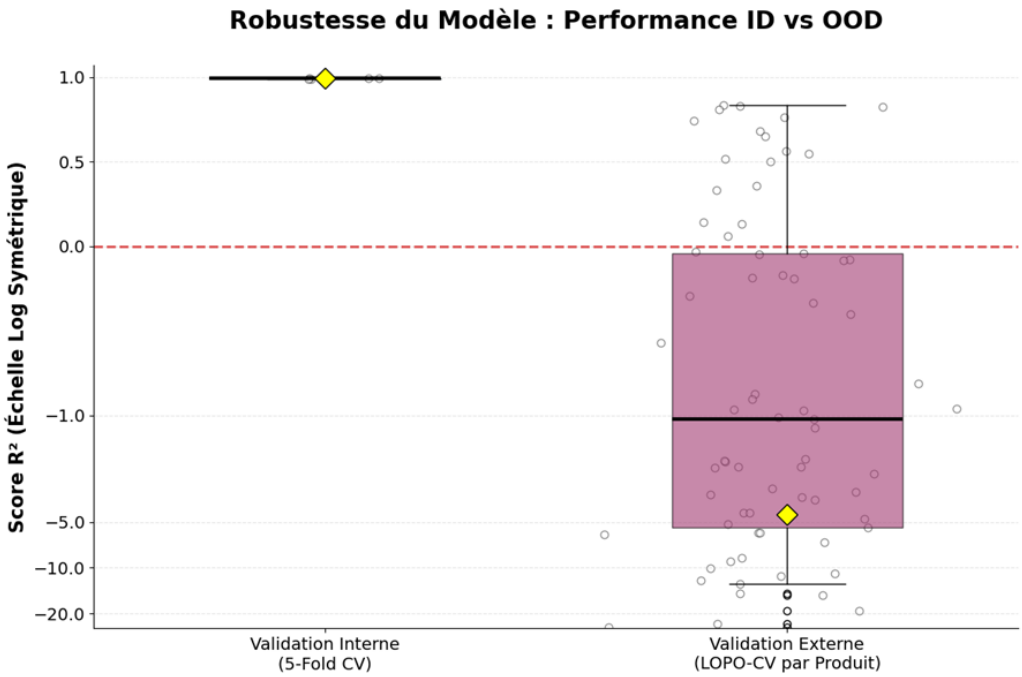

FIGURE 8 – Comparaison des R^2 des modèles All_features vs XGBoost OOD LOPO

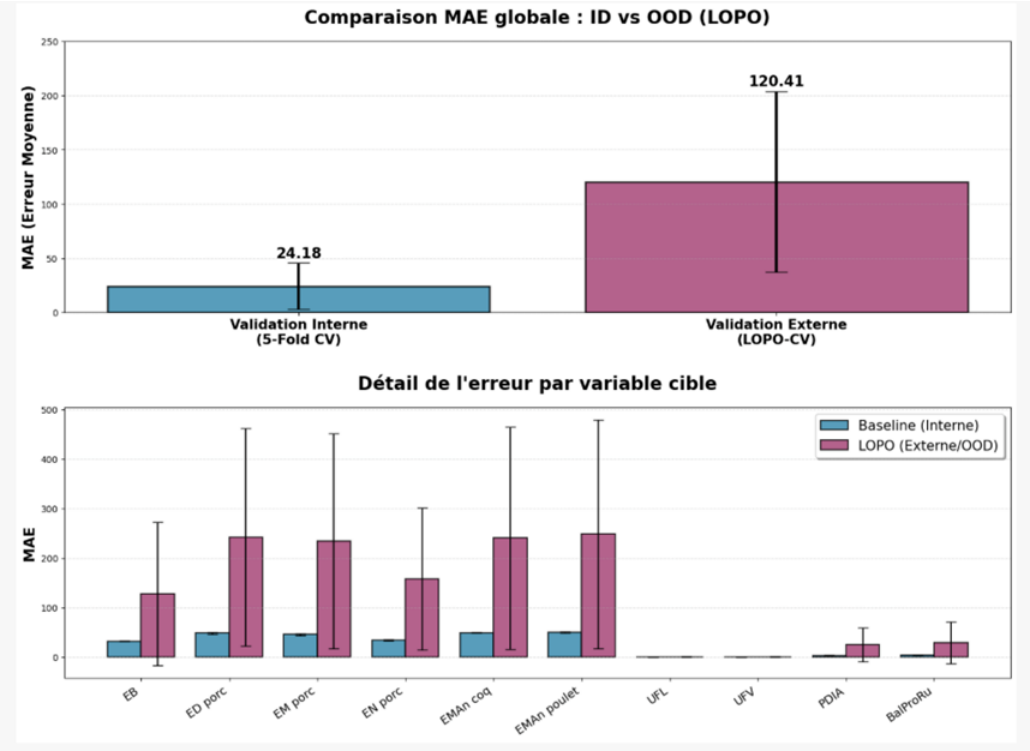

FIGURE 9 – Comparaison des MAE des modèles All_features vs XGBoost OOD LOPO

La figure 8 témoigne que le modèle de prédiction XGBoost OOD est instable, proposant des prédictions très éloignées des valeurs nutritionnelles réelles, résultant en un R^2 moyen négatif. De plus, la figure 9 montre les limites de l'approche ensembliste en ID. En effet, nous constatons que l'erreur en OOD est très élevée pour certaines variables cibles comparativement à celles en ID. Nous pouvons alors émettre l'hypothèse que sans lien sémantique entre les espèces, le modèle ne peut pas transférer ses connaissances. Ainsi, le modèle XGBoost n'est pas exploitable selon ces configurations pour prédire des échantillons en OOD. Dans la suite de cette section, nous présenterons des méthodologies alternatives (embeddings, MLP, transformers, etc.) visant à pallier l'échec de la généralisation OOD observé avec le modèle *baseline*.

4.2 Utilisation du deep learning

4.2.1 Méthodologie

Nous avons mis en place le pipeline de traitement de *deep learning* afin de traiter les problématiques d'Out-of-Distribution. Ce pipeline sert de base à tous nos modèles de *deep learning* mis en place.

L'architecture de ce pipeline de traitement correspond à un encodage des embeddings par Sentence-BERT, dont nous réduisons la dimension à 16 via un encodeur gelé. Nous avons concaténé ces embeddings avec les variables physico-chimiques et avons fourni le tout à un régressseur (Perceptron Multi-Couche, Transformer ou XGBoost) qui prédit les valeurs cibles nutritionnelles. Le vecteur final présente 26 variables.

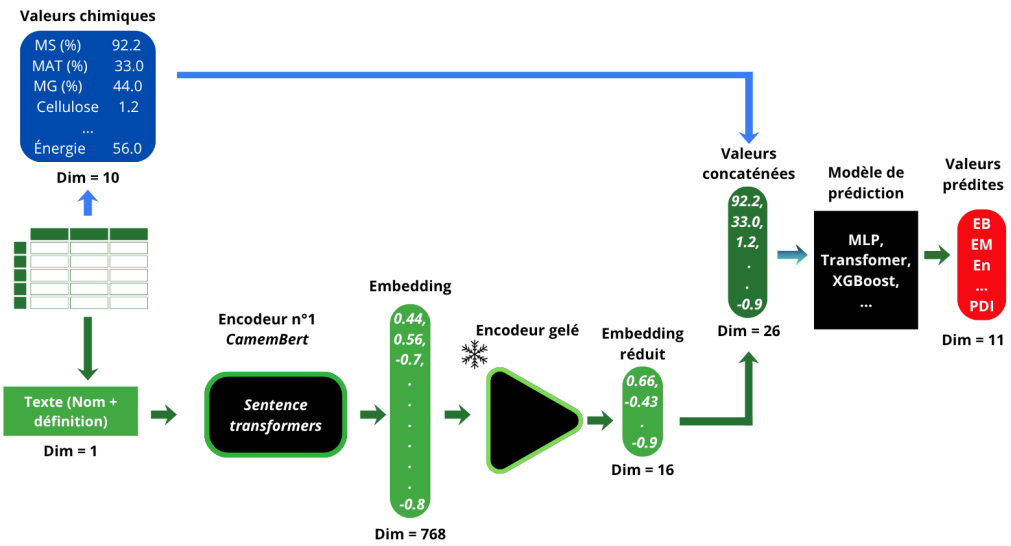

FIGURE 10 – Logigramme du pipeline général en apprentissage profond pour la gestion des données hors domaine d'apprentissage

4.2.2 Définition des embeddings

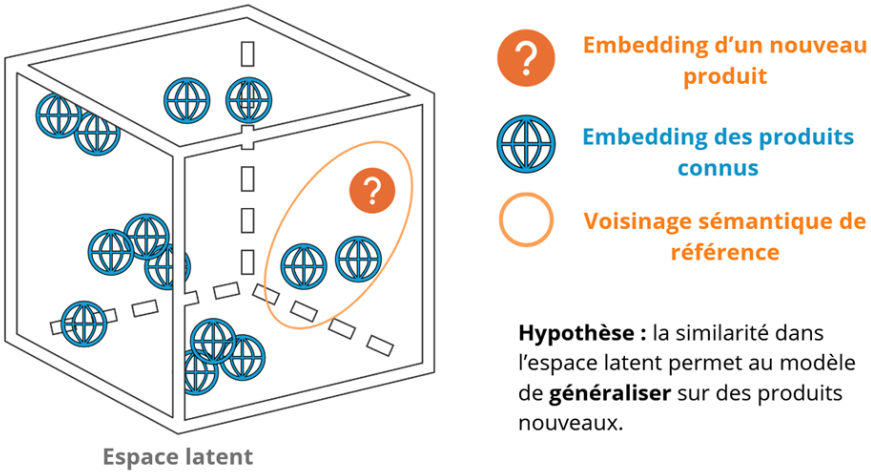

FIGURE 11 – Schéma explicatif de l'utilisation d'embedding (représentation de l'espace latent à partir d'une donnée textuelle)

Nous avons besoin d'une nouvelle source d'informations afin de gérer l'OOD. Pour pallier l'échec de l'OOD avec le modèle XGBoost, nous avons besoin de liens sémantiques entre les espèces. Si nous arrivons à générer une représentation du nouvel échantillon à partir de ses caractéristiques textuelles, nous pouvons espérer obtenir une information qui permettra de mieux représenter un aliment inconnu.

Pour générer ces embeddings, nous utilisons un modèle pré-entraîné, Sentence-BERT, basé sur l'architecture CamemBERT. Il s'agit d'un *Large Language Model* (LLM) encodeur entraîné sur des corpus français et correspond particulièrement à notre tâche. [4]

[5] Afin d'étayer nos descriptions textuelles qui ne contiennent initialement que les noms d'aliments, nous avons aussi récupéré sur les données Feedtables l'ensemble des définitions pour ces aliments. Cela permet d'ajouter des précisions textuelles, surtout pour les éléments qui sont OOD. Une fois le modèle sélectionné, nous passons en inférence l'ensemble des données textuelles, qui correspondent au NOM + définition d'un aliment. Nous obtenons donc une représentation de ces aliments dans un espace de représentation numérique de dimension 768.

4.2.3 Réduction du nombre de dimensions des embeddings par auto-encodage

Une fois les embeddings de Sentence-BERT obtenus, nous nous retrouvons face à un problème de dimensions. En effet, les variables physico-chimiques se comptent au nombre de 10. Ces dernières, dont l'importance est capitale pour améliorer la prédiction notamment en OOD, se trouvent alors noyées parmi les 768 dimensions de l'embedding textuel. Le modèle apprend alors principalement sur 768 descripteurs qui peuvent s'apparenter à un bruit global qui nous décrit le texte. Il est ainsi nécessaire de réduire ces dimensions afin de garder l'information nécessaire et suffisante pour représenter plus simplement les aliments.

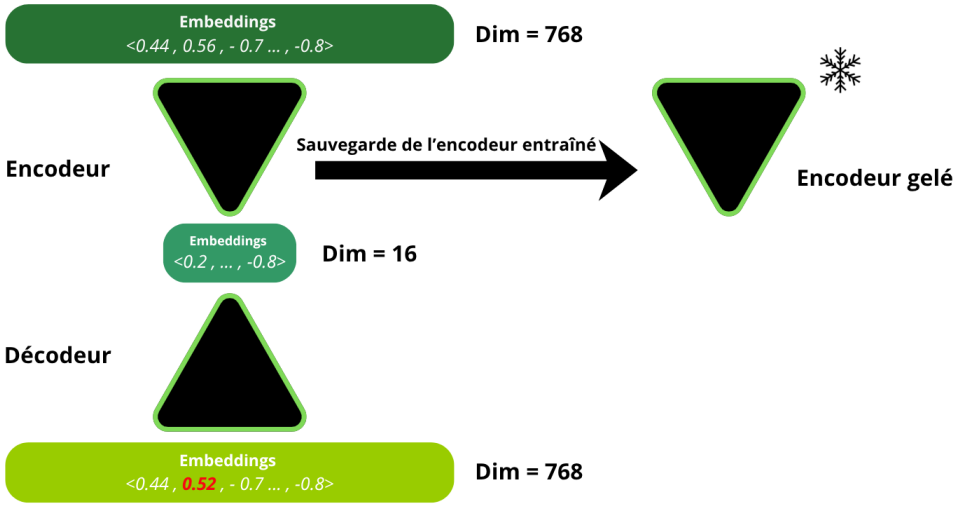

FIGURE 12 – Schéma décrivant le fonctionnement et l'entraînement d'un auto-encodeur)

La méthode employée pour réduire la dimension est basée sur un auto-encodeur ou encodeur miroir. Son but, lors de l'apprentissage, est de réduire correctement le vecteur de valeur initiale (dim = 768) dans un espace restreint (16) et d'ensuite reconstituer le vecteur initial à partir de l'espace réduit. Une fois l'apprentissage terminé, nous gelons les poids de l'encodeur, et l'utilisons ensuite en inférence afin de réduire les dimensions des embeddings issus de Sentence-BERT.

4.2.4 Premier modèle : Perceptron multi-couche

Dans un premier temps, nous avons créé un régresseur issu d'une architecture de Perceptron multicouche (nommé par la suite "MLPRegressor" ou "MLP"). Celui-ci possède la

structure suivante :

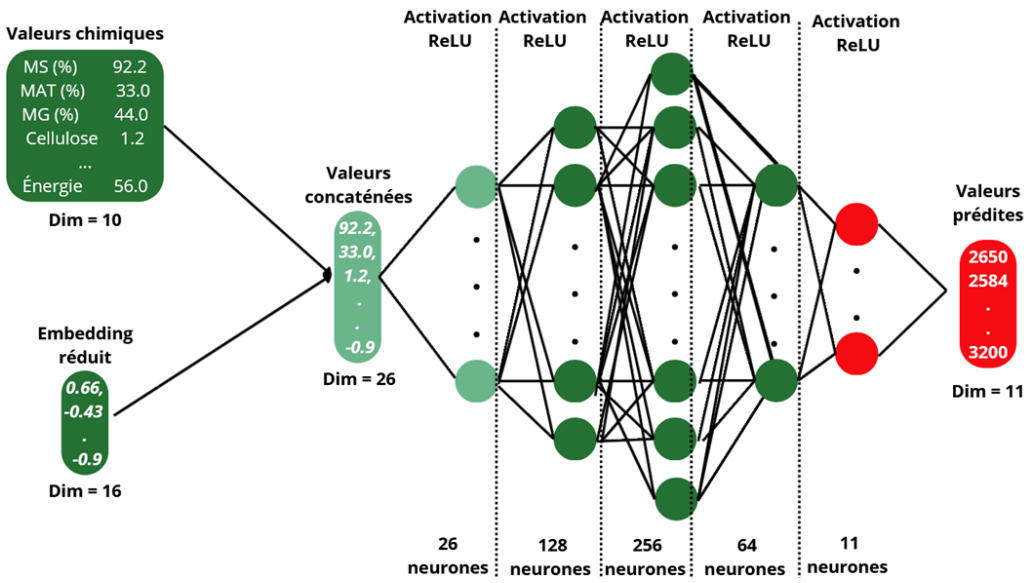

FIGURE 13 – Structure du perceptron multi-couche (MLPRegressor)

Cette architecture possède une limite qui est le risque de sur-apprentissage avec l'ensemble de ses neurones. Pour se prémunir de ce risque, nous effectuons un *dropout* de 0,2 lors de l'ensemble des *epochs*. Cela signifie que pour chaque couche, nous désactivons 20% des neurones de manière aléatoire et régularisons les poids du réseau.

4.2.5 Deuxième modèle qui permet de mieux gérer l'OOD et l'imputation de valeurs : le transformer

Pour aller plus loin, nous avons décidé de mettre en place une architecture transformer à la place du MLPRegressor. L'intérêt de cette architecture plus complexe est double : gérer l'OOD et imputer les valeurs physico-chimiques absentes dans les données d'entrées du modèle.

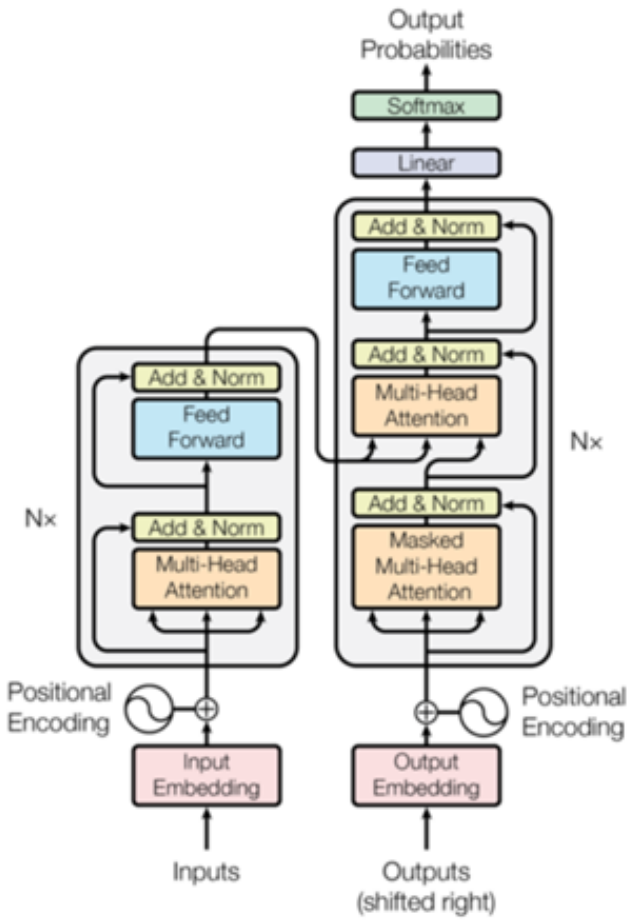

FIGURE 14 – Schéma de l'architecture Transformer avec une structure Encodeur/Décodeur

4.3 Résultats de la partie deep learning

4.3.1 Effet de l'OOD sur l'auto-encodeur

La première expérience réalisée évalue si la représentation par l'auto-encodeur (AE) gère correctement l'OOD. Pour ce faire, nous évaluons les R^2 de 10 aliments sélectionnés au hasard. Dans un cas, nous entraînons l'AE sur tous les noms existants dans nos tables puis nous réalisons de l'inférence sur les modèles MLP et Transformer (cas AE gelé en turquoise). Dans l'autre, nous entraînons l'AE sur tous les aliments sauf celui considéré comme hors distribution et passons ensuite l'embedding de dimension 768 en inférence dans l'encodeur pour réduire sa taille.

De manière générale, nous pouvons affirmer que l'auto-encodeur arrive bien à réduire l'information, même en situation OOD car nous obtenons des performances globalement similaires entre les deux situations. Il s'agit principalement de points extrêmes qui influent sur la distribution des résultats.

Par ailleurs, nous remarquons la présence de nombreux R^2 négatifs, surtout sur la partie MLPRegressor. Cela signifie que malgré un embedding textuel réduit, les différents

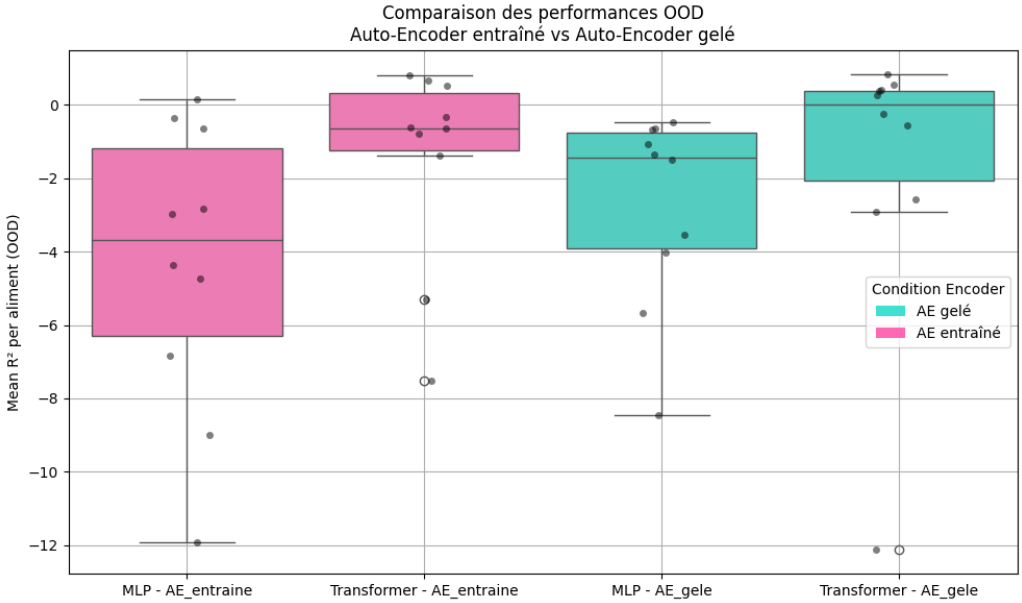

FIGURE 15 – Comparaison des performances OOD entre un auto-encodeur entraîné et un auto-encodeur gelé

régresseurs n'arrivent pas à prédire correctement les composantes d'un aliment inconnu. Le transformer arrive légèrement mieux à prédire des valeurs en OOD ce qui est quand même relativement encourageant.

4.3.2 Mesure des valeurs OOD : MLPRegressor vs Transformer

Nous avons réalisé un Leave-One-Product-Out (LOPO) sur l'ensemble des produits issus des données AFZ (73) et avons mesuré le R^2 moyen pour les valeurs cibles.

La figure 16 confirme ce qui a été démontré dans la partie précédente : le transformer possède de meilleures performances prédictives que le MLPRegressor. Cependant, la gestion de l'OOD est loin d'être optimale puisque le R^2 moyen est négatif ou proche de zéro pour le transformer.

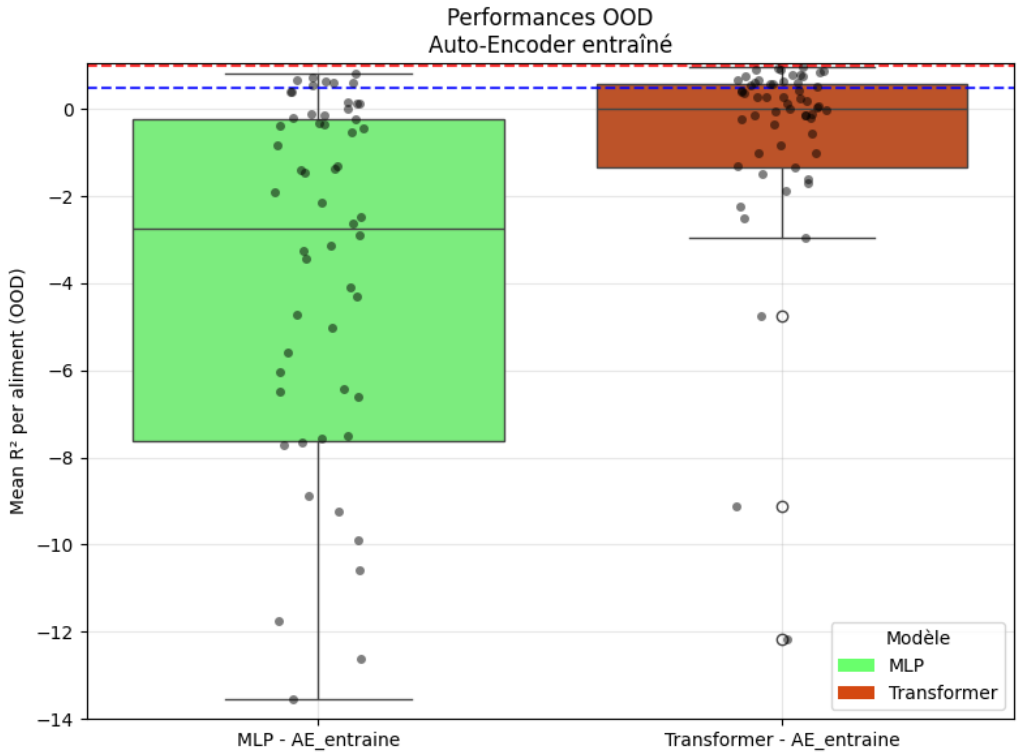

FIGURE 16 – Comparaison des R^2 scores entre le MLPRegressor et le transformer. NB : la ligne bleue vaut $y = 0{,}5$ et la rouge $y = 1$

4.3.3 Imputation de valeurs par transformer

L'intérêt de l'architecture Transformer est notamment de pouvoir réaliser des prédictions malgré des variables d'entrées masquées. Dans tous les cas, les variables d'entrées MS et PB ne sont jamais cachées car ce sont des variables auxquelles l'opérateur aura toujours accès.

Nous avons décidé d'évaluer notre modèle dans 3 situations :

- L'une où il reçoit en entrée l'ensemble des variables physico-chimiques (scénario bleu), il n'y a alors aucune imputation réalisée.
- L'une où l'on masque de manière aléatoire 50% des descripteurs autres que MS et PB (scénario vert), quatre descripteurs sont alors imputés.
- Le dernier scénario où nous masquons l'ensemble des descripteurs qui ne sont pas MS et PB (scénario rouge), les huit autres descripteurs sont alors imputés.

Nous étudions par ailleurs deux cas, le cas où les données testées sont ID et le cas où elles sont OOD.

Cas In-Distribution Le scénario vert où 50% des variables physico-chimiques sont imputées donne des résultats équivalents à ceux où aucune imputation n'est réalisée : R^2 moyen proche de 0,99. De plus, l'imputation de la totalité des variables physico-chimiques autres que MS et PB montre des résultats tout aussi encourageants, malgré une légère baisse de la performance par rapport au scénario vert, le R^2 reste élevé et avoisine les 0,965. Dans tous les cas, l'imputation via le transformer semble meilleure que celle via la méthode des valeurs moyennes vue en II.D.

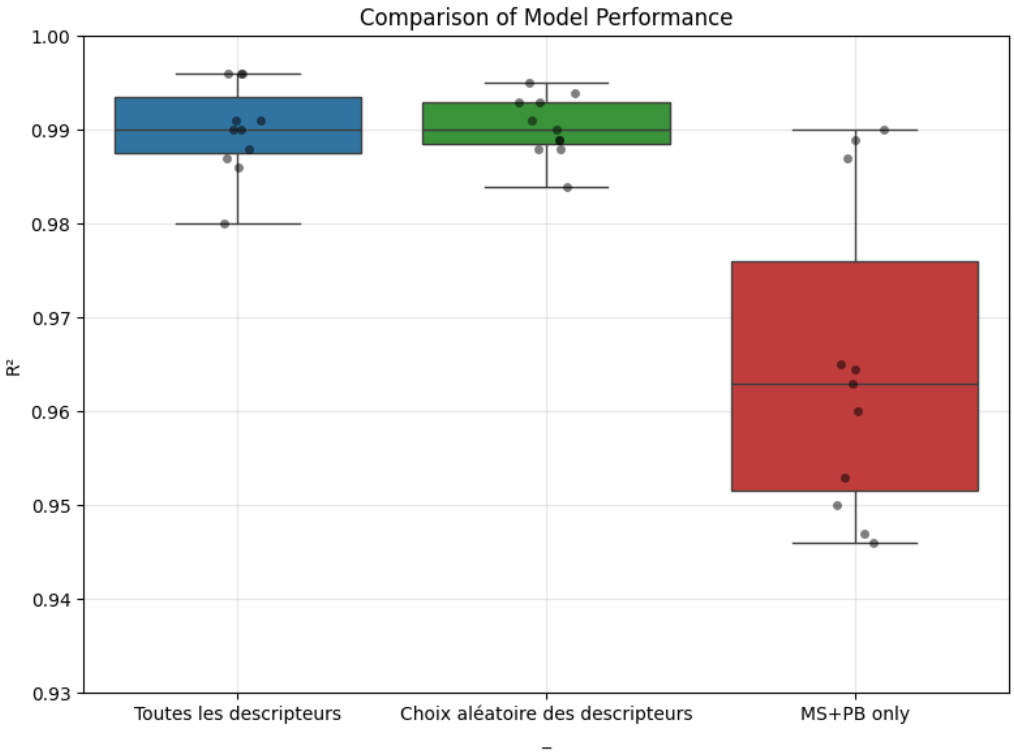

FIGURE 17 – Résultats de l'imputation des variables d'entrées manquantes par le modèle transformer

Cas Out-of-Distribution Nous avons testé ce scénario et les résultats s'effondrent. Cela n'est pas surprenant car nous essayons de prédire un aliment inconnu sans lui fournir des données physico-chimiques fiables.

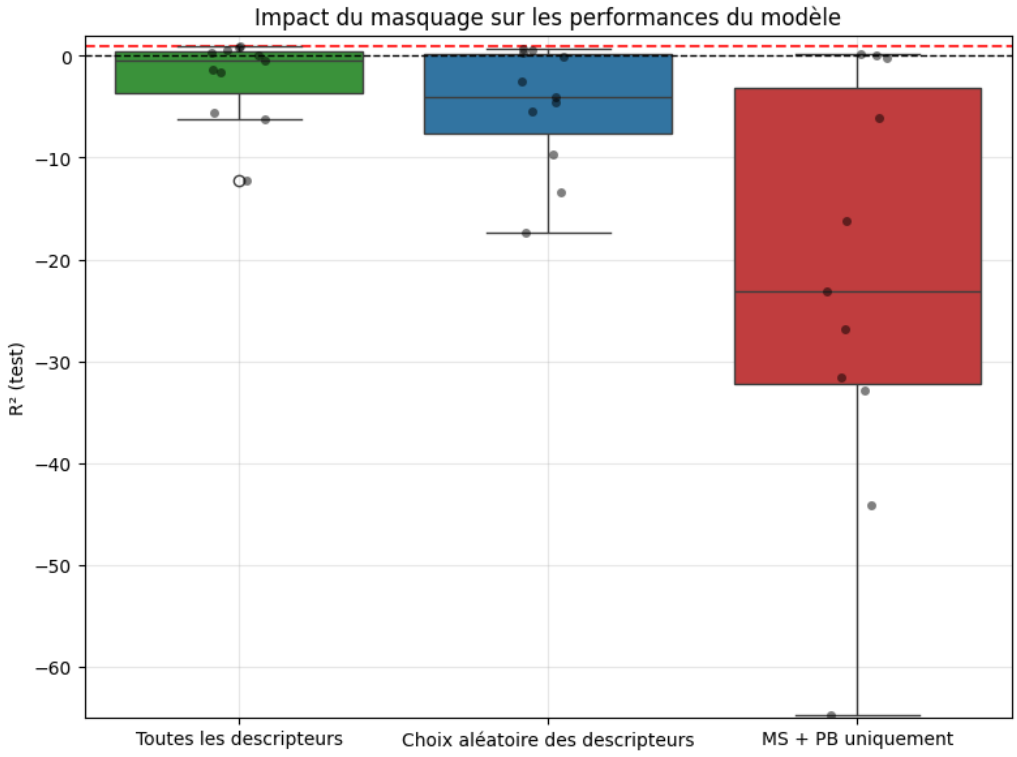

FIGURE 18 – Cas hors-distribution avec les variables imputées par le transformer

5 Discussion

5.1 Synthèse des résultats

Ainsi, notre démarche présente les performances de prédiction dans les différentes configurations utiles aux cas d'usage sur le terrain. Les performances *In Distribution* démontrent des R^2 se situant entre 0,92 et 0,99 selon les configurations des variables d'entrée.

En essayant de généraliser notre approche en prédisant des valeurs dans une situation *Out-of-Distribution*, les modèles initiaux XGBoost se sont avérés inexploitables car peu performants.

Plusieurs alternatives ont été étudiées afin de pouvoir traiter la situation OOD. Des architectures s'appuyant sur des réseaux de neurones ont été déclinées afin de créer un espace de projection de nouvelles instances OOD (via des embeddings) et être capables de prédire des valeurs nutritionnelles. Les modèles de régression utilisés pour prédire à partir des embeddings furent les suivants : MLPRegressor, Transformer, XGBoost.

Après avoir mené une étude comparée des performances de ces derniers, nous avons conclu que le transformer était le plus performant dans une situation OOD. La performance de ce modèle reste cependant à nuancer au vu de la faible valeur de R^2 obtenue.

Des erreurs de prédictions sont observées à travers ces modèles tout comme de très faibles R^2. Nous nous interrogeons donc sur les sources de ces erreurs.

5.2 Recherche des causes d'erreur en OOD : remise en question de la représentation sémantique

L'analyse des performances en situation hors-distribution (OOD) révèle une dégradation importante des performances, et ce même sur des produits a priori proches de la distribution d'entraînement. Nous devons donc nous interroger sur le fondement même de notre approche : la représentation latente via embeddings encodés a-t-elle du sens pour cette tâche de prédiction nutritionnelle ? Nos embeddings ont-ils une sémantique réellement exploitable ? Nous avons supposé que l'espace latent capturé par l'auto-encodeur (768D $\rightarrow$ 16D) préserverait les structures sémantiques pertinentes pour la prédiction des valeurs nutritionnelles. Cette hypothèse repose sur l'idée que deux produits "proches" dans cet espace latent seraient nutritionnellement similaires et faciliteraient la généralisation. Pour évaluer si l'isolement d'un produit dans l'espace latent explique ses difficultés de prédiction en OOD, nous avons besoin de quantifier deux dimensions complémentaires de cet isolement :

- Similarité maximale : mesure la proximité immédiate, c'est-à-dire la plus forte similarité cosinus avec un autre produit (hors soi-même). Cela indique si un produit possède un "voisin" proche dans l'ensemble d'entraînement, susceptible de servir de proxy pour la prédiction.
- Distance sémantique moyenne : mesure l'isolement global, soit la moyenne des distances (1 - similarité cosinus) avec tous les autres produits. Cette métrique reflète la densité locale d'exemples similaires et la position du produit dans l'espace latent.

Puis l'analyse consiste à comparer les performances prédictives (R^2 local en Leave-One-Product-Out Cross-Validation (LOPO-CV)) à ces deux métriques. Hypothèse de base : lors de la LOPO-CV, le modèle est entraîné sur tous les produits sauf un. Si un produit nutritionnellement similaire à celui-ci existe dans cet ensemble d'entraînement, il peut servir de proxy pour généraliser. Cette métrique capture seulement le meilleur voisin. Si deux produits sont très proches (sim = 0,99) mais isolés du reste, cette proximité pourrait être accidentelle ou due au bruit. D'où la nécessité du complément : distance sémantique moyenne. Hypothèse : l'isolement d'un produit n'est pas défini par un seul voisin, mais par sa position globale dans l'espace latent. Un produit peut avoir un ami proche mais être éloigné de tous les autres. Ainsi, cela nous permet de mieux refléter la densité locale d'exemples similaires.

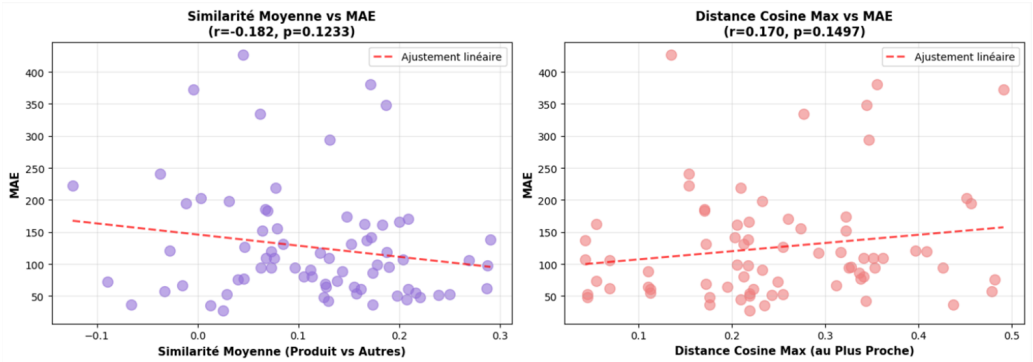

FIGURE 19 – Comparaison des similarités moyennes et de la distance cosinus

Dans l'espace 16D compressé, aucune corrélation forte n'est observée entre similarité sé-

mantique et performance OOD. Cela suggère que la structure de l'embedding réduite ne capture pas la similarité nutritionnelle pertinente pour la tâche de prédiction. Ce constat est d'autant plus marquant que l'embedding intègre à la fois le nom et la définition du produit, donc une information textuelle détaillée. Pourtant, cette richesse ne se traduit pas par une organisation pertinente de l'espace latent pour la prédiction nutritionnelle hors distribution. L'apport de ces embeddings pour la généralisation en OOD reste donc très limité dans notre cas.

5.3 Vers un usage utilisateur

Une des requêtes des experts de l'AFZ a été de créer une interface utilisateur afin de pouvoir interagir facilement avec les modèles de prédictions. Nous avons créé un site internet qui permet d'évaluer un modèle d'XGBoost All_features+Nom avec une imputation de valeur par la valeur moyenne issue de Feedtables.

Une amélioration notable de cette interface pourrait être d'avoir le choix entre différents modèles en fonction des besoins précis de l'utilisateur, comme utiliser un modèle spécialisé pour la prédiction des valeurs nutritionnelles des céréales ou des tourteaux.

5.4 Piste d'ouverture

Afin de tenter un affinage de la représentation dans un espace latent, il pourrait être intéressant de mettre en place un modèle d'auto-encodeur variationnel [6] afin de mieux représenter les embeddings entre eux et créer un espace latent continu, qui pourrait permettre une meilleure représentation des échantillons OOD et préciser les proximités dans l'espace latent.

6 Conclusion

Ce projet a permis de répondre au besoin initial formulé par l'AFZ, à savoir simplifier l'accès aux valeurs nutritionnelles des aliments et proposer une alternative plus exploitable que l'enchaînement d'équations Excel actuellement utilisé. À partir d'un jeu de données structuré et particulièrement propre, nous avons montré qu'un modèle de type XGBoost est capable de prédire avec une très grande précision les différentes valeurs énergétiques et protéiques dans un cadre *in-distribution*. Les performances obtenues (R^2 élevés, erreurs faibles) confirment que la structure chimique des aliments est correctement capturée par le modèle, sans nécessiter de prétraitements lourds.

En revanche, l'étude des performances *out-of-distribution* révèle une limite importante. Lorsque le modèle est confronté à des produits insuffisamment représentés ou exclus lors de l'entraînement, les performances se dégradent de manière significative. Cette observation indique que, si le modèle apprend efficacement les relations internes au catalogue actuel, sa capacité de généralisation reste contrainte par la diversité limitée du jeu de données, aujourd'hui restreint à un nombre réduit de produits et de profils chimiques.

La suite du projet devra donc s'articuler autour d'une feuille de route claire. À court terme, il s'agira de consolider l'évaluation de la robustesse hors distribution et de formaliser les protocoles de validation par classe ou sous-classe. À moyen terme, l'extension et la diversification du jeu de données constituent un levier prioritaire afin d'élargir l'espace chimique couvert par le modèle. Enfin, des pistes d'approfondissement telles que l'intégration de descriptions textuelles ou le développement d'outils d'aide à la décision ne seront pertinentes que si la robustesse et la généralisation sont préalablement assurées.

Ainsi, le projet a permis d'établir une base méthodologique solide et un démonstrateur performant. L'enjeu principal n'est désormais plus la performance sur des aliments connus, mais la capacité à proposer un outil réellement généralisable, fiable et opérationnel pour des situations nouvelles.

Remerciements

Nous adressons tout d'abord nos plus sincères remerciements à Valérie Heuzé et Gilles Tran de l'Association Française de Zootechnie pour leur ambition, la confiance qu'ils nous ont accordée et l'enthousiasme constant avec lequel ils ont soutenu nos travaux. Nous exprimons également notre profonde gratitude à Christine Martin, Antoine Cornuéjols, Vincent Guigue et Liliana Ibanescu nos professeurs, pour leur accompagnement attentif, la qualité de leurs conseils, leur disponibilité ainsi que leur soutien précieux, tant sur le plan scientifique que méthodologique, tout au long de ce projet.

Références

1. INRAE-CIRAD-AFZ, "Tables of composition and nutritional values of feed materials," Feedtables.com, 2017–2024. [Online]. Available : https ://www.feedtables.com/. [Accessed : 25-Feb-2026].
2. X. Yao, X. Fu, et C. Zong, "Short-Term Load Forecasting Method Based on Feature Preference Strategy and LightGBM-XGBoost," School of Electronics and Information Engineering, Lanzhou Jiaotong University, Lanzhou.
3. L. Grinsztajn, E. Oyallon et G. Varoquaux, "Why do tree-based models still outperform deep learning on tabular data ?", in *Advances in Neural Information Processing Systems (NeurIPS) 35*, Datasets and Benchmarks Track, 2022. arXiv :2207.08815. [Online]. Available : https ://arxiv.org/abs/2207.08815. [Accessed : 25-Feb-2026].
4. Martin, Louis et al. (2020). "CamemBERT : a Tasty French Language Model". In : *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, p. 7203–7219. DOI : 10.18653/v1/2020.acl-main.645. arXiv : 1911.03894 [cs].
5. Antoun, Wissam et al. (13 nov. 2024). *CamemBERT 2.0 : A Smarter French Language Model Aged to Perfection*. DOI : 10.48550/arXiv.2411.08868. arXiv : 2411.08868.
6. Diederik P. Kingma and Max Welling, "Auto-Encoding Variational Bayes," arXiv preprint, arXiv :1312.6114, Dec. 2013.
7. A. Rush, "Attention is All You Need," Apr. 03, 2018. [Online]. Available : http ://nlp.seas.harvard. [Accessed : 25-Feb-2026].
8. A. Turbot et al., "Projet fil rouge : nutrition animale – démonstrateur de modélisation et prédiction nutritionnelle," GitHub repository. [Online]. Available : `https://github.com/alantrbt/Projet-fil-rouge-nutrition-animale-.git`. [Accessed : 25-Feb-2026].